



Université Cadi Ayyad École Supérieure De Technologie-Safi Département : Informatique

Filière :LP Ingénierie des Systèmes d'information et Réseaux

Rapport du Projet

Analyse des vols américains en 2023 : Conception et Réalisation d'un Data Warehouse pour une Intelligence Décisionnelle Avancée

Réalisé par :

M. Yahya LEMKHARBECH M. EL AOUMARI Abdelmoughith Encadré par :

Mme. MOUNIR Ilham

Année Universitaire: 2023/2024

Introduction générale

Au cœur de cette étude, portant sur une analyse approfondie des vols américains en 2023 avec la conception et la réalisation d'un Data Warehouse orienté vers une Intelligence Décisionnelle Avancée, nous structurons notre rapport en quatre chapitres distincts, chacun apportant une contribution spécifique à notre compréhension globale. Dans le premier chapitre, dénommé "Généralités", nous explorons les fondements de l'informatique décisionnelle, comparons les systèmes décisionnels et transactionnels, définissons les composants essentiels d'un Data Warehouse, et mettons en avant son rôle fondamental dans l'analyse de données. Notamment, nous détaillons le schéma OLAP utilisé, incluant une table de faits dédiée aux voyages et plusieurs dimensions telles que les billets, les vols (avec les dimensions villes et avions, cette dernière incorporant une dimension supplémentaire pour les fabricants), les passagers (avec une dimension de groupe d'âge), et la dimension temporelle. Le deuxième chapitre, axé sur l'"Implémentation", se concentre sur les technologies et les outils employés pour concrétiser le Data Warehouse. Les différentes phases de transformation et d'extraction des données, notamment à travers l'utilisation de Power BI, sont détaillées dans cette section. Le troisième chapitre, consacré au "Reporting", présente les résultats sous forme de tableaux de bord générés par Power BI, mettant en évidence la flexibilité et la puissance de cette plateforme dans l'analyse de données. Enfin, le quatrième chapitre, "Conclusion", offre une synthèse du projet, souligne les enseignements clés tirés de l'expérience, et esquisse des perspectives futures.

Table des matières

ın	troai	action	generale	2
I-	Gén	éralité	\mathbf{s}	7
	I.1	Introd	uction	7
	I.2	Inform	natique Décisionnelle	7
		I.2.1	Définition et Explication	7
		I.2.2	Importance de l'Informatique Décisionnelle	8
		I.2.3	Les Différentes Phases du Processus	8
			Collecte des Données	8
			Transformation des Données	8
			Stockage dans le Data Warehouse	8
			Analyse des Données	8
	I.3	Systèn	nes Décisionnels vs Systèmes Transactionnels	9
		I.3.1	Systèmes Transactionnels (OLTP)	9
		I.3.2	Systèmes Décisionnels (OLAP)	10
	I.4	Entrep	oôt de données (EDD)	10
		I.4.1	Définition d'entrepôt de données	10
		I.4.2	Composants d'entrepôt de données	11
		I.4.3	Les Différentes Notions liées à l'Entreposage de Données	12
	I.5	Conclu	ısion	13
ΙI٠	- Imp	plémer	ntation	15
	II.1	Introd	uction	15
	II.2	Logicie	els et outils utilisés	16
	II.3	Charge	ement des Données	18
		II.3.1	Chargement de données sous format Excel	18
		II.3.2	Chargement de données sous format JSON	19
		II.3.3	Chargement de données sous format XML	20
		II.3.4	Chargement de données à partir d'un base de données Mysql	22

II.4	Transf	formation des Données	24
	II.4.1	Transformation et indentification des dimensions	24
		Dimensions des dimensions	25
		Dimensions de la table de faits	28
	II.4.2	Table résultat "Travel"	33
II.5	Schém	a OLAP	33
II.6	Conclu	ısion	34
III- Re	epoting		35
III.1	Introd	uction	35
III.2	Requê	tes DAX	35
	III.2.1	Définition des Requêtes DAX	35
	III.2.2	Les Mesures Créées à l'Aide des Requêtes DAX	36
III.3	Tablea	u de bord	39
III.4	Conclu	asion	41
Conclu	sion g	énérale	42
Referei	nces		43

Table des figures

I.1	Schéma d'Informatique Décisionnelle	9
I.2	Architecture de Data Warehouse	12
II.1	Logo de Power BI	16
II.2	WampServer	16
II.3	PhpMyAdmin	17
II.4	Chargement depuis Excel (1)	18
II.5	Chargement depuis Excel(2)	19
II.6	Chargement depuis JSON (1)	19
II.7	Chargement depuis JSON (2)	20
II.8	Chargement depuis XML (1)	21
II.9	Chargement depuis XML (2)	21
II.10	Table "Manufacteurer" sur la base de données	22
II.11	Choisir le type de la base de données	22
II.12	Connexion àla base de données	23
II.13	Choisir la table de la base de données	23
II.14	Exemple de Nettoyage et Normalisation des Données des Passagers	25
II.15	Création d'une colonne conditionnelle.	25
II.16	Chargement de la table groupe d'age	26
II.17	Merger les deux tables	26
II.18	Exemple de Nettoyage et Normalisation des Données des Tickets	27
II.19	Chargement de la table classes de voyage	27
II.20	Merger les deux tables	28
II.21	Chargement de la table de fait	28
II.22	Création de la table "date"	29
II.23	Merger la table de fait avec date	29
II 24	Création de la table "passagers"	30

II.25 Merger la table de fait avec passagers	30
II.26 Création de la table "tickets"	31
II.27 Merger la table de fait avec tickets	31
II.28 Création de la table "flights"	32
II.29 Merger la table de fait avec flights	32
II.30 Résultat de la transformation des données	33
II.31 Schéma OLAP	34
III.1 Table de faits	36
III.2 Dashboard partie 1	39
III.3 Dashboard partie 2	40
III.4 Dashboard partie 3	40
III 5 Dashboard partie 4	41

I- Généralités

I.1 Introduction

Cette section introductive, consacrée aux généralités, constitue le point de départ de notre exploration approfondie sur l'analyse des vols américains en 2023, avec la conception et la réalisation d'un Data Warehouse dédié à une Intelligence Décisionnelle Avancée. Notre objectif est de jeter les bases nécessaires à la compréhension des concepts fondamentaux de l'informatique décisionnelle. Nous entamons ce voyage en mettant en lumière la distinction entre les systèmes décisionnels et transactionnels, offrant ainsi un aperçu des défis uniques liés à l'analyse de données massives.

Dans cette optique, nous définissons le concept central de notre étude, le Data Warehouse, en expliquant ses composants essentiels et en soulignant son rôle crucial dans la facilitation de l'analyse de données complexes. Une attention particulière est accordée au schéma OLAP que nous avons adopté, avec une table de faits dédiée aux voyages et des dimensions soigneusement sélectionnées telles que les billets, les vols (avec les dimensions des villes et des avions, cette dernière incorporant une dimension supplémentaire pour les fabricants), les passagers (comprenant une dimension de groupe d'âge), et la dimension temporelle.

Enfin, nous examinons l'importance stratégique d'un Data Warehouse dans le contexte de notre analyse spécifique des vols américains en 2023. Cette section jettera les bases nécessaires pour comprendre les choix conceptuels et techniques que nous avons opérés dans la conception de notre solution d'Intelligence Décisionnelle Avancée.

I.2 Informatique Décisionnelle

I.2.1 Définition et Explication

L'informatique décisionnelle (ID) est un domaine clé de l'informatique axé sur la collecte, le stockage et l'analyse de données pour soutenir les prises de décision stratégiques au sein d'une organisation. Elle englobe un ensemble de technologies, de processus et d'outils visant à transformer les données brutes en informations significatives et exploitables. L'ID repose souvent sur des bases de données spécialisées, telles que les Data Warehouses, pour consolider et organiser les données

de manière à faciliter une analyse plus approfondie.

I.2.2 Importance de l'Informatique Décisionnelle

L'importance de l'informatique décisionnelle réside dans sa capacité à fournir des insights cruciaux pour orienter les décisions stratégiques. Elle permet aux entreprises de mieux comprendre leur performance passée, d'évaluer les tendances actuelles et d'anticiper les opportunités futures. Dans la révolution de l'informatique, l'ID joue un rôle central en offrant aux décideurs un accès rapide et précis aux informations vitales, favorisant ainsi une prise de décision éclairée dans un environnement en constante évolution.

I.2.3 Les Différentes Phases du Processus

Collecte des Données

La première étape du processus d'informatique décisionnelle consiste à collecter des données provenant de diverses sources, qu'elles soient internes ou externes à l'organisation. Cela peut inclure des données opérationnelles, des données provenant de partenaires, des données issues de médias sociaux, etc.

Transformation des Données

Une fois les données collectées, la phase de transformation intervient. Cette étape implique le nettoyage, la normalisation et la structuration des données pour les rendre cohérentes et adaptées à l'analyse. Cela peut également inclure des opérations telles que l'agrégation et la conversion de formats.

Stockage dans le Data Warehouse

Les données transformées sont ensuite stockées dans un entrepôt de données dédié, souvent appelé Data Warehouse. Ce stockage organisé permet un accès rapide et efficace aux données pour les besoins d'analyse ultérieure.

Analyse des Données

La dernière phase du processus est l'analyse des données. Cela implique l'extraction d'informations significatives à partir des données stockées dans le Data Warehouse. Différentes techniques d'analyse, telles que les requêtes SQL, les rapports, et les outils d'analyse visuelle, peuvent être utilisées pour tirer des insights décisionnels.




FIGURE I.1 – Schéma d'Informatique Décisionnelle

Cette section éclairera le lecteur sur les fondements de l'informatique décisionnelle, son rôle crucial dans la révolution informatique, ainsi que les différentes phases du processus qui conduisent à des insights décisionnels significatifs.

I.3 Systèmes Décisionnels vs Systèmes Transactionnels

Un entrepôt de données est une collection de données où toutes les informations transactionnelles d'une organisation sont stockées, mais il n'est pas le même que la base de données transactionnelle. La principale différence est que cette dernière est conçue et optimisée pour stocker des données, tandis que les entrepôts de données sont conçus et optimisés pour répondre aux questions d'analyse qui sont essentielles pour les entreprises.

I.3.1 Systèmes Transactionnels (OLTP)

Les systèmes transactionnels, également appelés systèmes opérationnels (OLTP), sont dédiés aux opérations quotidiennes de l'entreprise. Ils sont conçus pour traiter des données détaillées, personnelles et identifiées, souvent sur une période relativement courte. Ces systèmes sont opérationnels en temps réel et contribuent directement aux tâches de gestion quotidienne. Les données

stockées dans les bases de données transactionnelles peuvent être de l'ordre de quelques centaines de mégaoctets à plusieurs giga-octets.

I.3.2 Systèmes Décisionnels (OLAP)

Les systèmes décisionnels, également connus sous le nom de systèmes OLAP, sont dédiés à la prise de décision stratégique et au pilotage de l'activité de l'entreprise. Ils offrent une vision transversale de l'entreprise en agrégeant et en historisant les données. Les informations entreposées dans un Data Warehouse (DW) sont considérées comme statiques, ne devant pas être modifiées, ce qui est fondamental pour l'analyse approfondie de l'organisation. Les utilisateurs des entrepôts de données sont généralement des analystes et des gestionnaires.

Caractéristiques	Système Transactionnel	Système Décisionnel (OLAP)	
	(OLTP)		
Applications	production	aide à la décision	
Utilisateurs	un département	professionnel IT, décideur non IT	
Données	normalisées, non agrégées	dénormalisées, agrégées	
Requêtes	simples, nombreuses	complexes, peu nombreuses	
Nb tuples invoqués	dizaines	millions	
par requête (moyenne)			
Taille données	100 MB à 1 GB	1 GB à 1 TB	
Ancienneté des don-	récente, mises à jour régu-	historique	
nées	lières		

Table I.1 – Comparaison entre Système Transactionnel et Système Décisionnel

Le tableau I.1 récapitule les principales différences entre un système transactionnel (OLTP) et un système décisionnel (OLAP).

I.4 Entrepôt de données (EDD)

I.4.1 Définition d'entrepôt de données

Un Data Warehouse (DW), ou entrepôt de données, est une plateforme centralisée de stockage de données qui permet aux organisations de consolider, organiser et analyser d'importantes quantités de données provenant de différentes sources. Conçu pour soutenir l'informatique décisionnelle, le DW offre une structure optimisée pour faciliter l'analyse et la génération de rapports, fournissant ainsi une base solide pour la prise de décision stratégique.

Le principal objectif d'un Data Warehouse est de permettre aux utilisateurs de tirer des insights significatifs à partir de données hétérogènes, souvent dispersées dans l'ensemble de l'entreprise.

En intégrant ces données, le DW offre une vision holistique de l'organisation, favorisant une compréhension approfondie de ses performances passées, présentes et futures.

I.4.2 Composants d'entrepôt de données

Un Data Warehouse est composé de plusieurs éléments clés, chacun jouant un rôle spécifique dans le processus global d'analyse des données. Les principaux composants comprennent :

- Extraction des Données : La zone de staging est la première étape où les données brutes sont extraites des sources externes. Ces données sont stockées temporairement avant d'être nettoyées et transformées pour répondre aux besoins analytiques du DW.
- Transformation des Données: La zone de transformation est dédiée à la préparation des données. C'est ici que les données sont nettoyées, normalisées et structurées de manière à faciliter l'analyse ultérieure. Les processus ETL (Extraction, Transformation, Load) sont souvent appliqués dans cette phase.
- Entrepôt de Données : L'entrepôt de données est la partie centrale du DW où les données nettoyées et transformées sont stockées de manière organisée. Cette structure optimisée facilite les requêtes complexes et les rapports analytiques.
- Métadonnées : Les métadonnées fournissent des informations sur les données stockées dans le DW. Elles incluent des descriptions de données, des définitions, des schémas, facilitant ainsi la compréhension et l'interprétation des informations contenues dans le DW.

La figure suivante illustre l'architecture typique d'un Data Warehouse, montrant comment ces composants interagissent pour fournir une plateforme robuste d'analyse des données.




FIGURE I.2 – Architecture de Data Warehouse

I.4.3 Les Différentes Notions liées à l'Entreposage de Données

- Granularité: La granularité en entreposage de données se réfère au niveau de détail des données stockées. Il s'agit de déterminer le degré de précision auquel les informations sont enregistrées dans le Data Warehouse. Une granularité fine signifie que les données sont enregistrées de manière très détaillée, tandis qu'une granularité grossière signifie qu'elles sont agrégées à un niveau plus élevé.
- **Dimension**: Une dimension représente une catégorie ou une perspective selon laquelle les données peuvent être analysées. Par exemple, dans un Data Warehouse lié aux ventes, les dimensions peuvent inclure le temps, le produit, le lieu et le client. Les dimensions aident à organiser et à structurer les données pour faciliter l'analyse.
- **Fait**: Un fait, également appelé mesure, représente une valeur numérique que l'on souhaite analyser. Dans un contexte de ventes, le montant de ventes mensuelles pourrait être une mesure. Les faits sont associés à des dimensions pour fournir un contexte lors de l'analyse.
- Data Mart: Un Data Mart est une sous-section d'un Data Warehouse qui est dédiée à un domaine spécifique de l'entreprise, tel que les ventes, les finances ou les ressources humaines. Contrairement à un Data Warehouse complet qui couvre l'ensemble de l'organisation, un Data Mart se concentre sur des données spécifiques à un département ou à une équipe. Il offre une vue plus ciblée et spécialisée des données pour répondre aux besoins analytiques particuliers d'une unité fonctionnelle.

- **Hiérarchie**: La hiérarchie représente la structure organisée des différents niveaux au sein d'une dimension. Par exemple, une dimension de temps peut avoir une hiérarchie avec des niveaux tels que année, trimestre, mois, etc. Les hiérarchies facilitent l'agrégation des données à différents niveaux de détail.
- Schéma en Étoile : Le schéma en étoile est un modèle de conception de Data Warehouse dans lequel une table centrale de faits est entourée de tables de dimensions. La table centrale de faits contient les mesures que l'on souhaite analyser, tandis que les tables de dimensions fournissent le contexte pour ces mesures.
- Schéma en Flocon : Le schéma en flocon est une variation du schéma en étoile où les tables de dimensions sont normalisées pour réduire la redondance des données. Cela se fait en décomposant les dimensions en sous-dimensions, créant ainsi une structure en forme de flocon.
- Data Mart : Un Data Mart est une sous-section d'un Data Warehouse qui est dédiée à un domaine spécifique de l'entreprise, tel que les ventes, les finances ou les ressources humaines. Contrairement à un Data Warehouse complet qui couvre l'ensemble de l'organisation, un Data Mart se concentre sur des données spécifiques à un département ou à une équipe. Il offre une vue plus ciblée et spécialisée des données pour répondre aux besoins analytiques particuliers d'une unité fonctionnelle.
- ETL (Extraction, Transformation, Load) : ETL est un processus essentiel dans la gestion des données d'un Data Warehouse. Il implique l'extraction des données à partir de sources diverses, la transformation pour les préparer à l'analyse, puis le chargement dans le Data Warehouse. Ce processus garantit la qualité et la cohérence des données.

I.5 Conclusion

La conception et la réalisation d'un Data Warehouse pour l'analyse approfondie des vols américains en 2023 ont été abordées à travers plusieurs perspectives tout au long de ce rapport. Nous avons débuté par une introduction générale mettant en lumière l'importance de l'informatique décisionnelle et de l'entreposage de données dans le contexte de notre analyse.

Dans la section sur les généralités, nous avons exploré les concepts fondamentaux de l'informatique décisionnelle, comparé les systèmes décisionnels aux systèmes transactionnels, défini le Data Warehouse, et discuté des concepts liés tels que la granularité, les dimensions, les faits, et les schémas en étoile et en flocon.

La section d'implémentation a mis en lumière les technologies et les outils utilisés, ainsi que les différentes étapes du processus d'extraction, de transformation et de chargement des données dans le Data Warehouse. Nous avons également présenté un aperçu du reporting à travers la démonstration d'un tableau de bord réalisé avec Power BI.

La section suivante a approfondi les notions liées à l'entreposage de données, mettant en avant des concepts tels que la granularité, les dimensions, les faits, les Data Marts, les hiérarchies, et les schémas en étoile et en flocon. Ces concepts sont cruciaux pour la structuration efficace des données dans le Data Warehouse.

En conclusion, la réalisation de ce Data Warehouse offre une plateforme solide pour l'analyse avancée des vols américains en 2023. Les composants soigneusement conçus, les notions clés intégrées et les outils puissants de reporting permettent une exploration approfondie des données, offrant ainsi des insights précieux pour la prise de décision stratégique.

Ce projet souligne l'importance croissante de l'informatique décisionnelle et de l'entreposage de données dans le domaine de l'aviation et illustre comment ces technologies peuvent être mises en œuvre de manière pratique pour répondre aux besoins spécifiques d'analyse et d'intelligence décisionnelle.

En résumé, la conception et la réalisation de ce Data Warehouse représentent une avancée significative dans l'exploitation des données pour une meilleure compréhension des tendances et des facteurs influençant le secteur de l'aviation américaine en 2023.

II- Implémentation

II.1 Introduction

Le chapitre d'implémentation marque une étape cruciale dans la concrétisation de notre projet d'analyse approfondie des vols américains en 2023 à travers la conception et la mise en œuvre d'un Data Warehouse. Cette phase est subdivisée en quatre parties essentielles, chacune abordant un aspect spécifique du processus d'implémentation.

Dans la première partie, nous explorerons les logiciels et les outils sélectionnés pour soutenir le déploiement du Data Warehouse, de la plateforme de gestion de base de données aux outils d'analyse et de visualisation. Cette section expose les décisions prises pour garantir une infrastructure adaptée aux besoins du projet.

La deuxième partie aborde le processus d'extraction des données, soulignant la sélection des sources, les méthodes d'extraction et les mécanismes de stockage temporaire. Cette phase revêt une importance cruciale pour assurer la qualité et l'intégrité des données dans l'environnement du Data Warehouse.

la troisième partie couvre les étapes d'extraction, de transformation et de chargement (ETL) des données. Nous détaillerons les processus visant à nettoyer, normaliser et organiser les données avant leur chargement dans le Data Warehouse, garantissant ainsi des données cohérentes et prêtes à être explorées.

Enfin, La quateriéme partie met l'accent sur le schéma OLAP (Online Analytical Processing), cœur du système. Nous détaillerons la conception du schéma, mettant en lumière les dimensions, les faits et les hiérarchies choisis pour organiser les données et fournir une base solide pour les analyses multidimensionnelles.

Chaque section contribue de manière significative à la création d'une infrastructure robuste, préparant ainsi le terrain pour des analyses approfondies et des prises de décision éclairées basées sur des données fiables et bien structurées.

II.2 Logiciels et outils utilisés



FIGURE II.1 – Logo de Power BI

Power BI: Power BI est un outil puissant de Business Intelligence développé par Microsoft. Il offre des fonctionnalités avancées d'analyse et de visualisation de données, permettant aux utilisateurs de transformer des ensembles de données brutes en informations significatives. Avec une interface conviviale, Power BI propose des tableaux de bord interactifs, des rapports dynamiques et des fonctionnalités de partage, facilitant la compréhension des tendances et des insights.

Power BI prend en charge la connexion à diverses sources de données, facilitant l'intégration des données extraites pour l'analyse. Les fonctionnalités de modélisation de données, les capacités d'ETL (Extraction, Transformation, Load) et la variété des visualisations graphiques en font un choix privilégié pour la création de rapports et de tableaux de bord percutants. En exploitant la puissance de Power BI, notre projet d'analyse approfondie des vols américains en 2023 bénéficie d'un outil de visualisation de données moderne et efficace, offrant une expérience interactive aux utilisateurs pour explorer et comprendre les informations clés.



FIGURE II.2 – WampServer

— WampServer: Pour la mise en place d'un environnement de développement web sous Windows, nous avons opté pour WampServer. Incluant Apache, MySQL et PHP, cet ou-

til a simplifié le déploiement local de notre application, assurant une cohérence entre les environnements de développement.



FIGURE II.3 – PhpMyAdmin

PhpMyAdmin: PhpMyAdmin est une application web open source écrite en PHP, conçue pour administrer de manière conviviale les bases de données MySQL via une interface graphique. Elle offre aux utilisateurs la possibilité de gérer efficacement les bases de données, les tables, les champs, les relations, les utilisateurs et les privilèges, le tout sans nécessiter une connaissance approfondie des commandes SQL. PhpMyAdmin simplifie la gestion et la manipulation des bases de données MySQL, en offrant une interface visuelle intuitive et des fonctionnalités telles que l'importation, l'exportation et la modification des données, facilitant ainsi le travail des développeurs et des administrateurs de bases de données.

II.3 Chargement des Données

Le chargement des données dans Power BI est une étape cruciale pour exploiter les informations stockées dans le Data Warehouse. Cette section explore le processus de chargement des données à partir de différents formats, illustré par des captures d'écran des opérations effectuées.

II.3.1 Chargement de données sous format Excel

Les données de la table flight sont chargées à partir d'un fichier Excel. Power BI facilite le chargement en permettant la sélection du fichier Excel, puis en identifiant automatiquement les tables et en les important dans le modèle de données.




FIGURE II.4 – Chargement depuis Excel (1)




FIGURE II.5 – Chargement depuis Excel(2)

II.3.2 Chargement de données sous format JSON

La table cities est au format JSON. Power BI prend en charge le chargement de données à partir de fichiers JSON. En spécifiant le chemin du fichier JSON, les données sont importées et disponibles pour l'analyse.




FIGURE II.6 – Chargement depuis JSON (1)




FIGURE II.7 – Chargement depuis JSON (2)

II.3.3 Chargement de données sous format XML

Pour la table **groupAges** au format XML, Power BI propose également une fonctionnalité de chargement direct. En sélectionnant le fichier XML, les données sont analysées et ajoutées au modèle.




FIGURE II.8 – Chargement depuis XML (1)




FIGURE II.9 – Chargement depuis XML (2)

II.3.4 Chargement de données à partir d'un base de données Mysql

La table Manufacturer est stockée dans une base de données MySQL. Power BI offre des connecteurs pour les bases de données relationnelles, permettant une connexion directe. En fournissant les informations de connexion, les données sont importées dans le modèle.



FIGURE II.10 - Table "Manufacteurer" sur la base de données




FIGURE II.11 – Choisir le type de la base de données




FIGURE II.12 – Connexion àla base de données

Note : Pour établir une connexion avec la base de données, vous devez spécifier trois informations essentielles :

- L'adresse IP du serveur de base de données.
- Le numéro de port utilisé pour la connexion.
- Le nom de la base de données à laquelle vous souhaitez accéder.




FIGURE II.13 – Choisir la table de la base de données

II.4 Transformation des Données

Le processus de transformation des données est essentiel dans la construction d'un Data Warehouse, car il permet de modeler les données pour répondre aux besoins d'analyse. Cette section explore deux aspects fondamentaux de la préparation des données : la transformation et l'identification des dimensions.

II.4.1 Transformation et indentification des dimensions

La première sous-section se concentre sur la transformation des données, en mettant particulièrement l'accent sur l'identification et la définition des dimensions. La transformation des dimensions joue un rôle crucial dans la construction de schémas de données significatifs, facilitant ainsi une analyse approfondie. Nous explorerons les différentes techniques et méthodes utilisées pour transformer les données et identifier les dimensions pertinentes.

Dimensions des dimensions

Transformation de la Table Passagers et Identification de la Dimension "Groupe Âge" Dans cette étape, nous détaillerons le processus de transformation de la table des passagers (passengers) et l'identification de la dimension "Groupe Âge". Cette dimension est cruciale pour segmenter les passagers en fonction de leur âge, facilitant ainsi une analyse plus granulaire des données.



FIGURE II.14 – Exemple de Nettoyage et Normalisation des Données des Passagers

Nouvelle colonne "groupe d'âge" créée conditionnellement à partir de la colonne existante "âge".




FIGURE II.15 – Création d'une colonne conditionnelle.




FIGURE II.16 – Chargement de la table groupe d'age

Nous avons fusionné les deux tables "Passenger" et "GroupeAge" en identifiant les colonnes communes entre les deux tables. Ensuite, nous avons identifié dans la table résultante les colonnes qui seront placées dans la première table "Passengers". Dans ce cas, la colonne identifiée est "IDGroupeAge".




FIGURE II.17 – Merger les deux tables

Transformation de la Table Tickets et Identification de la Dimension "Classe de voyage" Dans cette étape, nous détaillerons le processus de transformation de la table des passagers (tickets) et l'identification de la dimension "Classe de voyage". Cette dimension est cruciale pour segmenter les passagers en fonction de leur classes de ticket, facilitant ainsi une analyse plus granulaire des données.




FIGURE II.18 – Exemple de Nettoyage et Normalisation des Données des Tickets




FIGURE II.19 – Chargement de la table classes de voyage




FIGURE II.20 – Merger les deux tables

Dimensions de la table de faits

— **Dimension "Dates"** Nous avons créé une nouvelle table où chaque date est identifiée par son ID, puis nous l'avons combinée avec la table de faits.




FIGURE II.21 – Chargement de la table de fait




FIGURE II.22 – Création de la table "date"




FIGURE II.23 – Merger la table de fait avec date

— **Dimension "Passagers"** Nous avons créé une nouvelle table où chaque passager est identifiée par son ID, puis nous l'avons combinée avec la table de faits.




FIGURE II.24 – Création de la table "passagers"




FIGURE II.25 – Merger la table de fait avec passagers

— **Dimension "Tickets"** Nous avons créé une nouvelle table où chaque Ticket est identifiée par son ID, puis nous l'avons combinée avec la table de faits.



FIGURE II.26 – Création de la table "tickets"




Figure II.27 – Merger la table de fait avec tickets

— **Dimension "Flights"** Nous avons créé une nouvelle table où chaque Flight est identifiée par son ID, puis nous l'avons combinée avec la table de faits.




FIGURE II.28 – Création de la table "flights"




Figure II.29 – Merger la table de fait avec flights

II.4.2 Table résultat "Travel"

Finalement, la table de faits contient tous les identifiants de ses dimensions, assurant ainsi une intégration complète des données dans notre modèle.

1 ² ₃ DateID	1 ² ₃ PassengerID ▼	1 ² ₃ FlightID ▼	1 ² ₃ TicketID ▼
193	44980	9718	1
5	23328	28940	2
361	16224	7382	3
222	45026	12976	4
322	37864	20862	5
314	34026	12920	6
294	12227	24544	7
64	24672	21611	8
355	18090	12476	9
14	20741	453	10
302	37214	769	11

FIGURE II.30 – Résultat de la transformation des données

II.5 Schéma OLAP

Ce schéma OLAP définit les relations entre la table des faits "travel" et les différentes dimensions associées (Dates, Tickets, Flights, Passangers), ainsi que les tables de dimensions imbriquées (Classes, Aircrafts, Manufacturer, Cities, Groupes). Ces dimensions facilitent l'analyse multidimensionnelle des données de voyage en fonction de divers attributs tels que la date, le prix des billets, les détails des vols, les passagers et leurs groupes d'âge.




FIGURE II.31 – Schéma OLAP

II.6 Conclusion

Le chapitre d'implémentation a été essentiel pour concrétiser notre projet d'analyse approfondie des vols américains en 2023. Nous avons présenté les outils clés tels que Power BI, WampServer et phpMyAdmin, choisis pour leur efficacité dans la modélisation et la gestion des données.

Le chargement des données a démontré la polyvalence de Power BI pour intégrer divers formats tels que JSON, Excel, XML et MySQL, documenté à travers des captures d'écran. La transformation des données a été approfondie, mettant en avant la création de dimensions cruciales pour les passagers, les tickets, et autres aspects.

La conclusion de cette phase a été marquée par la présentation de la table résultat, reflétant le résultat du travail de transformation des données. Nous avons également souligné le rôle crucial du schéma OLAP dans la génération de rapports interactifs et de tableaux de bord pour une analyse approfondie des informations stockées.

En somme, ce chapitre a établi une base solide pour la suite du projet, positionnant notre équipe pour exploiter pleinement des données structurées et bien préparées. La prochaine étape consistera à exploiter ces données pour répondre aux objectifs analytiques du projet et fournir des informations précieuses aux parties prenantes.

III- Repoting

III.1 Introduction

Le chapitre de reporting marque une étape essentielle dans notre projet d'analyse approfondie des vols américains en 2023. Dans cette phase, nous explorerons les aspects cruciaux de la création de rapports et de tableaux de bord, mettant l'accent sur l'utilisation de requêtes DAX (Data Analysis Expressions) pour formuler des mesures pertinentes et la conception de tableaux de bord interactifs.

La première section de ce chapitre se penche sur les Requêtes DAX, offrant une compréhension approfondie de cette langue spécifique à Power BI. La sous-section de définition éclairera les fondamentaux de DAX, tandis que la sous-section sur les mesures créées détaillera les mesures spécifiques que nous avons élaborées pour notre analyse.

La deuxième section se concentrera sur la conception de Tableaux de bord, expliquant comment nous avons structuré visuellement les informations pour permettre une exploration intuitive des données. Ces tableaux de bord fourniront une interface utilisateur conviviale pour interagir avec les résultats de notre analyse approfondie, facilitant ainsi la prise de décision basée sur des insights solides.

Chaque aspect de ce chapitre contribue à la création d'un environnement de reporting robuste, fournissant aux utilisateurs une plateforme puissante pour explorer et comprendre les résultats de notre projet d'analyse des vols américains en 2023.

III.2 Requêtes DAX

III.2.1 Définition des Requêtes DAX

Les Requêtes DAX (Data Analysis Expressions) sont un ensemble de formules et d'expressions utilisées dans Power BI pour effectuer des calculs et manipuler les données. DAX est spécifiquement conçu pour les outils de modélisation de données tels que Power BI, Excel Power Pivot et SQL Server Analysis Services (SSAS). Il offre une syntaxe similaire aux formules Excel, mais avec des fonctionnalités avancées pour travailler avec des modèles de données tabulaires.

Les Requêtes DAX sont utilisées pour créer des mesures, des colonnes calculées et des tableaux virtuels, permettant ainsi de dériver de nouvelles informations à partir des données existantes. Ces requêtes peuvent effectuer divers calculs, agrégations, filtrages et manipulations de données dans un modèle tabulaire.

Une caractéristique clé des Requêtes DAX est leur capacité à travailler avec des relations entre les tables, permettant d'effectuer des calculs contextuels basés sur des filtres appliqués dans les visualisations. Ces expressions sont évaluées dans le contexte de ligne ou de cellule, fournissant des résultats dynamiques et interactifs.

En résumé, les Requêtes DAX offrent un moyen puissant et flexible d'exprimer des calculs dans les modèles de données tabulaires, ouvrant la voie à une analyse approfondie et à la création de rapports personnalisés dans Power BI et d'autres outils compatibles.

III.2.2 Les Mesures Créées à l'Aide des Requêtes DAX

Voici quelques-unes des mesures créées à l'aide des Requêtes DAX, appliquées sur la table de faits "Travel" :




FIGURE III.1 – Table de faits

Total Revenue : Cette mesure nous permet d'analyser de manière ciblée les dépenses liées aux billets en fonction de groupes d'âge spécifiques à des dates particulières, offrant ainsi une vue précise des tendances de coûts dans notre ensemble de données.

```
CALCULATE(
    SUM('Tickets'[Price]),
    FILTER(
        ALL('Dates'),
        'Dates'[DateID] = MAX('travel'[DateID])
),

FILTER(
        ALL('groupes'),
        'groupes'[ID] = MAX('Passengers'[goupeAgeId])
)
)
```

— **Flight Count :** La requête CALCULATE utilise la fonction COUNT pour compter le nombre d'occurrences de "FlightID" dans la table "Flights". Les résultats sont filtrés en fonction de deux critères supplémentaires : la date maximale dans la table "Travel" et l'ID de classe maximal dans la table "Tickets".

```
CALCULATE(
    COUNT('Flights'[FlightID])
    FILTER(
     ALL('Dates'),
    'Dates'[DateID] = MAX('travel'[DateID])
),
FILTER(
    ALL('classes'),
    'classes'[ID] = MAX('Tickets'[classeId])
)
)
```

— **Total Distance**: Nous avons utilisé la fonction SUMX pour calculer la somme pondérée des distances des vols dans la table "Flights" pour chaque enregistrement de la table "Travel". Cela a été réalisé en filtrant les résultats en fonction de la date maximale de la table "Travel" et de l'ID de classe maximal dans la table "Tickets".

```
SUMX (
    'Travel',
    RELATED('Flights'[Distance])
        FILTER(
        ALL('Dates'),
        'Dates'[DateID] = MAX('travel'[DateID])
),
FILTER(
        ALL('classes'),
        'classes'[ID] = MAX('Tickets'[classeId])
)
)
```

— Passenger Count : La requête CALCULATE utilise DISTINCTCOUNT pour obtenir le nombre distinct de "PassengerID" dans la table "Travel". Elle est filtrée en fonction de la date maximale dans la table "Travel" et de l'ID de classe maximal dans la table "Tickets".

```
CALCULATE(
    DISTINCTCOUNT('travel' [PassengerID]),
    FILTER(
        ALL('Dates'),
        'Dates' [DateID] = MAX('travel' [DateID])
),
FILTER(
        ALL('classes'),
        'classes' [ID] = MAX('Tickets' [classeId])
```

III.3 Tableau de bord

Première page du tableau de bord - Total Revenue : La page d'ouverture du tableau de bord met en avant la mesure principale "Total Revenue", dérivée des prix des billets. Elle offre une vue globale des statistiques financières, présentant des visualisations claires pour une compréhension immédiate. Cette page donne un aperçu succinct mais informatif de la performance financière générale du secteur des voyages.



FIGURE III.2 – Dashboard partie 1

Deuxième page du tableau de bord - Total Distances : Cette page met en avant la mesure "Total Distance" avec des filtres interactifs pour explorer les données par date, destination, type d'aéronef, et classe de billet. Les visualisations dynamiques offrent une analyse précise de la distance totale parcourue, permettant une compréhension rapide des tendances en fonction de différentes dimensions.



FIGURE III.3 – Dashboard partie 2

Troisième page du tableau de bord - Total Passagers : La deuxième page du tableau de bord met en lumière la mesure "Total Passagers" avec des filtres interactifs pour explorer les données par date, destination, classe de billet et groupe d'âge. Quatrième page du tableau



FIGURE III.4 – Dashboard partie 3

de bord - Carte Interactive des Vols : La quatrième page présente une carte interactive où les villes sont visualisées en fonction du nombre de vols associés. Cette approche permet une exploration visuelle rapide de la densité des activités aériennes, offrant une perspective immédiate sur les hubs majeurs et les tendances géographiques. Cette visualisation cartographique dynamique facilite l'analyse spatiale des données de vols.




FIGURE III.5 – Dashboard partie 4

III.4 Conclusion

Le chapitre de reporting a été une étape cruciale dans notre parcours d'analyse approfondie des vols américains en 2023. En explorant les subtilités des requêtes DAX, nous avons pu formuler des mesures personnalisées offrant des perspectives uniques sur les données. Ces expressions puissantes ont permis de calculer des agrégations complexes, éclairant des aspects tels que l'âge moyen par date, destination et avion, ou encore le revenu total par classe, ville et groupe d'âge. La section suivante a donné vie à ces calculs à travers un tableau de bord interactif, offrant une visualisation dynamique des tendances et des insights clés. Les figures présentent des captures d'écran de ce tableau de bord, démontrant comment les données sont transformées en informations exploitables. Ce chapitre marque ainsi la transition de la phase d'analyse à la communication des résultats, préparant le terrain pour des prises de décision éclairées basées sur des données approfondies.

Conclusion générale

Le présent rapport a couvert un large éventail de sujets liés à l'analyse des données des vols américains en 2023, mettant en lumière les principaux aspects de la modélisation, de l'implémentation et du reporting dans le contexte de l'informatique décisionnelle.

Dans le chapitre "Généralités", l'introduction a établi le cadre du projet en présentant ses objectifs et en soulignant l'importance de l'informatique décisionnelle. La distinction entre les systèmes décisionnels et transactionnels a été clairement exposée, mettant en évidence leurs rôles respectifs dans la gestion des données.

Le chapitre "Implémentation" a plongé plus profondément dans les aspects pratiques du projet. L'introduction a présenté les logiciels et outils utilisés, avec un accent particulier sur Power BI, WampServer et PhpMyAdmin. Les schémas OLTP ont été détaillés, décrivant la structure des tables conçues pour capturer les transactions opérationnelles. Le chargement des données a été illustré à travers différents formats tels que Excel, JSON, XML et MySQL. La transformation des données a été abordée, montrant comment les données brutes ont été nettoyées, normalisées et préparées pour le Data Warehouse. Le schéma OLAP a ensuite été présenté, offrant une vue d'ensemble des données prêtes pour l'analyse.

Le dernier chapitre, "Reporting", a introduit les requêtes DAX, mettant l'accent sur leur rôle dans l'analyse des données. Les mesures créées ont été présentées avec des exemples concrets, offrant un aperçu des calculs effectués pour générer des insights significatifs. La section sur les tableaux de bord a complété le chapitre, montrant visuellement comment les données peuvent être explorées de manière dynamique.

En conclusion, ce rapport a mis en lumière le processus complet, du concept initial à la réalisation pratique, démontrant la valeur de l'informatique décisionnelle dans l'analyse approfondie des données. Les différentes phases, de la modélisation à l'implémentation et au reporting, ont été traitées de manière exhaustive, offrant une compréhension complète du projet et de son impact potentiel sur la prise de décision.

References

- Kaggle. (2023). "Flights in the United States 2023." Retrieved from Kaggle: https://www.kaggle.com/usdot/flight-delays (Consulté le 5 décembre 2023).
- Data.gov. (2023). "U.S. Department of Transportation Bureau of Transportation Statistics." Retrieved from Data.gov: https://www.transtats.bts.gov/ (Consulté le 8 décembre 2023).
- Microsoft Power BI Documentation. (Consulté le 14 décembre 2023). Retrieved from Power BI Documentation: https://docs.microsoft.com/en-us/power-bi/
- Microsoft Learn Power BI. (Consulté le 6 janvier 2024). Retrieved from Microsoft Learn: https://learn.microsoft.com/en-us/power-bi/
- Microsoft Docs DAX (Data Analysis Expressions). (Consulté le 8 janvier 2024).
 Retrieved from Microsoft Docs : https://docs.microsoft.com/en-us/dax/ (Consulté le 26 décembre 2023)
- YouTube Tutorial. (2023). "Introduction to Data Warehousing and Business Intelligence." Retrieved from YouTube: https://youtu.be/AGrl-H87pRU (Consulté le 9 décembre 2024).